

Living Abroad

사용자의 나이, 학력, 경력, 영어 능력, 보유 자금과 선호 국가를 분석하여 캐나다·호주·영국 중 적합한 해외 취업·이주 경로를 추천하는 AI 기반 플랫폼입니다.

국가 환경 데이터 분석, 비자 규칙 판정, 경력·직업 유사도 분석과 공식 정책 문서 기반 RAG 상담을 제공합니다.

곽진아

saysthabout@gmail.com



시스템 개요01

- 시스템 소개

시스템 마무리04

- 트러블 슈팅
- 프로젝트 소감

시스템 기획02

- 타겟 사용자 분석
- 기술 스택
- 요구사항 분석
- 개발 일정

별첨05


- 단위 테스트
- 통합 테스트
- 서비스 검증

시스템 설계03

- 시스템 아키텍처
- CI/CD 아키텍처
- 프로세스 흐름도
- 메뉴 구조도
- 기능 명세서
- 화면 설계서
- ERD
- 핵심 테이블 정의서
- RAG 기반 LLM 답변 생성 구조
- LLM으로 Qwen 을 선택한 이
- pgvector 선택 이유
- AI/ML/DL 전처리 방법
- K-Means

시스템 개요

- 시스템 소개



시스템 소개

Living Abroad는 **해외 취업**과 **기술이민**을 준비하는 사용자의 나이, 학력, 경력, 영어 능력, 보유 자금과 선호 국가를 분석하여 **캐나다·호주·영국** 중 적합한 이주 경로를 추천하는 **AI 기반 해외 이주 지원 플랫폼**입니다.

공개된 이민 통계와 국가 환경 데이터를 머신러닝으로 분석하고, 사용자의 경력기술서와 국가별 직업 분류 데이터를 임베딩 기반으로 비교하여 경력·직업군 유사도를 산출합니다.


또한 국가별 비자 자격 요건을 규칙 기반으로 점검하고, 공식 정부 정책 문서를 활용한 RAG 기반 AI 상담을 통해 비자 조건, 필요 서류, 준비 절차를 출처와 정보 기준일과 함께 제공합니다.

Living Abroad는 실제 비자 승인 가능성을 예측하거나 법률적 판단을 제공하는 서비스가 아니라, 복잡하게 흩어진 **해외 취업·이민 정보를 한곳에서 비교**하고 사용자가 자신의 조건에 맞는 **준비 방향을 쉽게 파악할 수 있도록 돕는 것을 목표**로 합니다.



시스템 기획

- 타겟 사용자 분석
- 기술 스택
- 시스템 아키텍처
- CI/CD 아키텍처
- 업무 프로세스
- 요구사항 분석
- 개발 일정



타겟 사용자	주요 니즈
해외 이주 초기 탐색형	해외 취업이나 이민에 관심은 있지만, 어느 국가가 자신에게 적합한지아직 결정하지 못한 사용자
비자 자격 진단형	해외 취업이나 이민에 관심은 있지만, 어느 국가가 자신에게 적합한지아직 결정하지 못한 사용자본인의 나이, 학력, 경력, 영어 점수로 캐나다·호주·영국의 대표 비자 조건을 얼마나 충족하는지 확인하고 싶은 사용자
해외 직업 매칭형	국내에서 쌓은 경력과 기술이 해외의 어떤 직업군과 유사한지, 취업 가능성이 높은 직업은 무엇인지 알고 싶은 사용자
이주 준비 실행형	목표 국가와 비자를 어느 정도 결정했으며, 필요한 서류·영어 조건·신청 절차 등 구체적인 준비 정보를 확인하고 싶은 사용자

구분	적용 기술
Frontend	Node.js 24.16.0, npm 11.13.0, Vue 3.5.39, Vite 8.1.1, TypeScript 6.0.2, Pinia 3.0.4, Vue Router 5.1.0, Axios 1.18.1, Tailwind CSS 4.3.2
Backend	Java 17, Spring Boot 4.1.0, Spring Framework 7.0.x, Spring Security 7.1.x, Spring Data JPA 4.1.x, Hibernate ORM 7.x, Gradle 9.5.1
AI Server	Python 3.12.10, FastAPI 0.139.0, Pydantic 2.13.4, Uvicorn 0.51.0
AI 데이터 처리	Pandas 3.0.3, NumPy 2.5.1, OpenPyXL 3.1.5
Machine Learning	Scikit-learn 1.9.0, Joblib 1.5.3
Deep Learning	PyTorch 2.13.0, Sentence Transformers 5.6.0, intfloat/multilingual-e5-base
LLM-RAG	Qwen3-8B-AWQ, OpenAI Python SDK 2.46.0, psycopg2-binary 2.9.12, pgvector-python 0.5.0
Database	PostgreSQL 18 (배포/Docker), pgvector 0.8.2, PostgreSQL JDBC Driver (Spring Boot BOM 관리)
API Test	Postman, Springdoc OpenAPI 3.0.3
Test	Spring Boot Test 4.1.0, JUnit Jupiter 5.12.2, Mockito 5.17.0, Vitest 4.1.10, Vue Test Utils 2.4.11, Pytest 9.1.1
CI/CD	Docker Engine, Docker Compose, Nginx 1.30-alpine, GCP Compute Engine (e2-medium, Debian 13), RunPod Serverless (vLLM GPU 호스팅), Let's Encrypt (certbot, sslip.io), DagsHub

요구사항 ID	요구사항
FR-COM-001	시스템은 공통 헤더에 로고와 주요 메뉴를 표시해야 한다.
FR-COM-002	시스템은 사용자의 로그인 여부에 따라 표시 메뉴를 변경해야 한다.
FR-COM-003	비로그인 사용자가 보호 화면에 접근하면 로그인 화면으로 이동해야 한다.
FR-COM-004	API 처리 중 로딩 상태를 표시하고 중복 요청을 방지해야 한다.
FR-COM-005	API 오류 발생 시 사용자가 이해할 수 있는 오류 메시지를 표시해야 한다.
FR-COM-006	분석 결과와 PI 상담 화면에 면책 문구를 표시해야 한다.

요구사항 ID	요구사항
FR-AUTH-001	사용자는 이름, 이메일과 비밀번호를 입력하여 회원가입할 수 있어야 한다.
FR-AUTH-002	사용자는 구글계정을 이용하여 로그인할 수 있어야 한다.
FR-AUTH-003	시스템은 이메일 형식과 비밀번호 조건을 검증해야 한다.
FR-AUTH-004	시스템은 중복 이메일 가입을 차단해야 한다.
FR-AUTH-005	비밀번호는 BCrypt 등 단방향 암호화 방식으로 저장해야 한다.
FR-AUTH-006	사용자는 이메일과 비밀번호로 로그인할 수 있어야 한다.
FR-AUTH-007	로그인 성공 시 JWT를 발급해야 한다.
FR-AUTH-008	보호 API 요청 시 JWT 인증을 적용해야 한다.
FR-AUTH-009	사용자는 로그아웃할 수 있어야 한다.
FR-AUTH-010	만료되거나 유효하지 않은 토큰 사용 시 재로그인을 요청해야 한다.

요구사항 ID	요구사항
FR-PROF-001	사용자는 나이를 입력할 수 있어야 한다.
FR-PROF-002	사용자는 최종 학력과 전공을 입력할 수 있어야 한다.
FR-PROF-003	사용자는 현재 직업과 관련 경력 연수를 입력할 수 있어야 한다.
FR-PROF-004	나이는 18세 이상 64세 이하로 검증해야 한다.
FR-PROF-005	경력 연수는 0년 이상 40년 이하로 검증해야 한다.
FR-PROF-006	시스템은 사용자 프로필을 저장하고 다시 조회할 수 있어야 한다.
FR-PROF-007	사용자는 저장된 프로필을 수정할 수 있어야 한다.

요구사항 ID	요구사항
FR-ANA-001	사용자는 공인 언어시험 종류와 점수를 입력할 수 있어야 한다.
FR-ANA-002	시험을 선택한 경우 해당 시험의 점수 범위를 검증해야 한다.
FR-ANA-003	사용자는 보유 자금 구간을 선택할 수 있어야 한다.
FR-ANA-004	사용자는 가족 동반 여부를 선택할 수 있어야 한다.
FR-ANA-005	사용자는 캐나다·호주·영국 또는 상관없음을 선호 국가로 선택할 수 있어야 한다.
FR-ANA-006	사용자는 경력과 담당 업무를 경력기술서로 입력할 수 있어야 한다.
FR-ANA-007	경력기술서는 최대 2,000자까지 입력할 수 있어야 한다.
FR-ANA-008	필수 항목이 누락된 경우 분석 요청을 차단해야 한다.
FR-ANA-009	분석 요청 성공 시 고유한 분석 ID를 생성해야 한다.
FR-ANA-010	분석 진행 중에는 처리 상태와 안내 문구를 표시해야 한다.

요구사항 ID	요구사항
FR-RULE-001	시스템은 캐나다 Express Entry FSWJ의 공식 조건을 규칙 기반으로 분석해야 한다.
FR-RULE-002	시스템은 호주 Subclass 189의 공식 조건을 규칙 기반으로 분석해야 한다.
FR-RULE-003	시스템은 영국 Skilled Worker Visa의 공식 조건을 규칙 기반으로 분석해야 한다.
FR-RULE-004	비자 규칙에는 나이, 학력, 경력, 언어와 필요 자금 등의 조건을 반영해야 한다.
FR-RULE-005	영국 비자의 스폰서와 Job Offer 여부는 추가 확인 항목으로 처리해야 한다.
FR-RULE-006	판정 결과는 충족, 보완 필요, 추가 확인 필요로 제공해야 한다.
FR-RULE-007	비자 조건의 공식 출처 URL과 검증일을 저장해야 한다.
FR-RULE-008	정책 변경에 대응할 수 있도록 규칙값을 코드에 분산하지 않고 DB 또는 설정 파일로 관리해야 한다.

요구사항 ID	요구사항
FR-ML-001	시스템은 국가별 이민·고용·교육·정착 관련 데이터를 분석해야 한다.
FR-ML-002	K-Means 모델은 캐나다·호주·영국만이 아닌 전체 학습 국가를 사용해야 한다.
FR-ML-003	시스템은 국가별 환경 군집을 분류해야 한다.
FR-ML-004	시스템은 캐나다·호주·영국의 국가 환경 점수를 산출해야 한다.
FR-ML-005	환경 점수는 0점 이상 100점 이하로 반환해야 한다.
FR-ML-006	환경 점수는 비자 승인 가능성이 아닌 국가 환경 비교 지표로 사용해야 한다.
FR-ML-007	분석 결과에 모델 버전과 데이터 기준일을 포함해야 한다.

요구사항 ID	요구사항
FR-NLP-001	시스템은 사용자의 경력기술서를 텍스트 임베딩으로 변환해야 한다.
FR-NLP-002	캐나다 NOC, 호주 ANZSCO와 영국 SOC 직업 데이터를 사용해야 한다.
FR-NLP-003	직업 설명은 분석 요청 전에 미리 임베딩하여 저장해야 한다.
FR-NLP-004	사용자 경력과 직업 설명의 코사인 유사도를 계산해야 한다.
FR-NLP-005	국가별로 유사한 직업을 최대 3개까지 제공해야 한다.
FR-NLP-006	결과에는 직업 코드, 직업명과 유사도 점수를 포함해야 한다.
FR-NLP-007	한국어 경력기술서와 영어 직업 설명을 비교할 수 있는 다국어 임베딩 모델을 사용해야 한다.

요구사항 ID	요구사항
FR-RES-001	시스템은 캐나다·호주·영국의 종합 적합도를 계산해야 한다.
FR-RES-002	종합 점수에는 비자 규칙, 국가 환경, 경력 유사도와 사용자 선호 점수를 반영해야 한다.
FR-RES-003	가중치는 설정 파일 또는 DB에서 관리할 수 있어야 한다.
FR-RES-004	국가별 결과를 종합 점수 기준 내림차순으로 정렬해야 한다.
FR-RES-005	추천 결과 화면에 국가 TOP 3를 표시해야 한다.
FR-RES-006	각 국가의 대표 비자와 판정 상태를 표시해야 한다.
FR-RES-007	종합 점수와 세부 점수를 구분하여 표시해야 한다.
FR-RES-008	사용자에게 유리한 강점과 보완이 필요한 항목을 제공해야 한다.
FR-RES-009	비자 준비에 필요한 서류·시험·자금 체크리스트를 제공해야 한다.
FR-RES-010	추천 결과는 데이터베이스에 저장해야 한다.
FR-RES-011	추천 점수를 실제 승인 확률로 표현해서는 안 된다.


초기 가중치	
분석 항목	가중치
비자 규칙 점수	45%
국가 환경 점수	25%
경력·직업 유사도	20%
사용자 선호 점수	10%


요구사항 ID	요구사항
FR-RAG-001	사용자는 국가와 비자를 선택하고 질문을 입력할 수 있어야 한다.
FR-RAG-002	시스템은 질문을 임베딩하여 관련 공식 정책 문서를 검색해야 한다.
FR-RAG-003	국가 코드와 비자 코드를 검색 조건으로 사용할 수 있어야 한다.
FR-RAG-004	pgvector를 이용해 유사한 정책 문서 청크를 검색해야 한다.
FR-RAG-005	검색된 공식 문서를 근거로 LLM 답변을 생성해야 한다.
FR-RAG-006	답변에는 공식 문서명, 출처 URL과 정보 검증일을 포함해야 한다.
FR-RAG-007	검색 근거가 부족한 경우 답변을 임의로 생성하지 않아야 한다.
FR-RAG-008	근거가 없을 경우 공식 기관에 확인하라는 안내를 제공해야 한다.
FR-RAG-009	사용자 질문과 AI 답변을 상담 이력으로 저장해야 한다.
FR-RAG-010	사용자는 기존 상담 세션의 대화 이력을 조회할 수 있어야 한다.
FR-RAG-011	AI 상담은 법률 자문이 아니라는 안내를 표시해야 한다.

요구사항 ID	요구사항
FR-MY-001	사용자는 본인의 분석 이력을 조회할 수 있어야 한다.
FR-MY-002	분석 이력에는 분석일, 1순위 국가, 대표 비자와 종합 점수를 표시해야 한다.
FR-MY-003	분석 이력은 최신순으로 정렬되어야 한다.
FR-MY-004	사용자는 과거 분석 결과를 다시 열 수 있어야 한다.
FR-MY-005	다른 사용자의 분석 결과를 조회할 수 없어야 한다.
FR-MY-006	사용자는 내 결과 화면에서 새로운 분석을 시작할 수 있어야 한다.
FR-MY-007	사용자는 내 결과 화면에서 프로필 수정 화면으로 이동할 수 있어야 한다.

시스템 설계

- 시스템 아키텍처
- CI/CD 아키텍처
- 프로세스 흐름도
- 메뉴 구조도
- 기능 명세서
- 화면 설계서
- ERD
- 핵심 테이블 정의서
- RAG 기반 LLM 답변 생성 구조
- LLM으로 Qwen 을 선택한 이유
- pgvector 선택 이유
- AI/ML/DL 전처리 방법
- K-Means





1. 개발자

로컬 작업

- 코드 수정
- `git push origin main`

2. GitHub

트리거

- `on: push (main)`
- `workflow_dispatch` (수동 실행)

3. GitHub Actions Runner

appleboy/ssh-action

- SSH 키로 GCP VM 접속
- 원격 배포 스크립트 실행

4. GCP VM (원격 실행)

instance-living-abroad

```
1 git fetch origin
2 git reset --hard origin/main
3 docker compose up -d --build
4 docker compose restart nginx
5 docker image prune -f
```


🔑 GitHub Secrets (Settings → Secrets and variables → Actions)

GCP_HOST

GCP_USER

GCP_SSH_PRIVATE_KEY

✅ 라이브 반영 — <https://34.132.107.128.sslip.io> (수동 SSH 배포 없이 push 한 번으로 자동 갱신)





요구사항 ID	기능명	사용자	입력	출력	화면	API	관련 테이블 / AI 로직	예외 조건
F-ANALYSIS-001	분석 요청 생성	회원	나이(1864), 학력, 전공, 직업, 경력연수(040), 언어시험·점수, 자금 범위, 가족동반 여부, 선호국가, 경력기술서(100~2000자)	분석 ID, 상태(PENDING 등) — 202 Accepted, 이후 비동기 처리	분석 1·2단계 입력	POST /api/analyses	analyses, user_profiles	필수값 누락/범위 초과 시 400, 언어시험 선택 시 점수 미입력이면 검증 실패
F-ANALYSIS-002	최근 입력값 조회	회원	-	가장 최근 분석 요청 시 입력했던 값(재입력 편의용)	분석 1단계 (이전 입력 불러오기)	GET /api/analyses/latest-input	analyses	이전 분석 이력 없으면 빈 값
F-ANALYSIS-003	규칙 기반 비자 점수 산정	(시스템, 회원 요청에 의해 트리거)	나이·학력·경력·언어점수 등 프로필	국가·비자별 점수 + 근거 사유(강점/보완점)	- (내부 로직)	ai-server 내부	비자 규칙(visa_rules) — F-AI-001~003	규칙 미충족 항목은 보완점으로 명시
F-ANALYSIS-004	국가 환경 점수 산정	(시스템)	국가 코드	K-Means 기반 국가 환경 점수(0~100)	- (내부 로직)	ai-server 내부	environment_kmeans, joblib 등 사전 학습 모델 — F-AI-004~005	지원 3개국 (CAN/AUS/GBR) 외에는 해당 없음
F-ANALYSIS-005	경력·직업 유사도 산정	(시스템)	경력기술서(자유서술)	국가별 상위 유사 직업 + 유사도 점수	- (내부 로직)	ai-server 내부	occupations.embedding (pgvector) — F-AI-006~007	경력기술서가 100자 미만이면 요청 자체가 거부됨 (400)

요구사항 ID	기능명	사용자	입력	출력	화면	API	관련 테이블 / DB 로직	예외 조건
F-ANALYSIS-006	분석 결과 상세 조회	회원(본인만)	분석 ID	국가별 순위, 종합점수, 세부점수(규칙/환경/경력/선호), 상태, 강점/보완점, 면책조항	분석 결과 화면	GET /api/analyses/{analysisId}	analyses, analysis_country_results, analysis_result_reasons	타인의 분석 ID 조회 시 403/404, 존재하지 않으면 404
F-ANALYSIS-007	분석 이력 목록 조회	회원	페이지 번호, 페이지 크기	분석 이력 목록 (페이지네이션)	내 결과 화면	GET /api/analyses?page=&size=	analyses	이력 없으면 빈 목록
F-ANALYSIS-008	결과 공유 링크 생성	회원(본인만)	분석 ID	공유 토큰(URL에 포함)	분석 결과 화면 (공유 버튼)	POST /api/analyses/{analysisId}/share	analyses (공유 토큰 컬럼)	타인의 분석 ID면 거부
F-ANALYSIS-009	결과 공유 링크 해제	회원(본인만)	분석 ID	204 No Content	분석 결과 화면	DELETE /api/analyses/{analysisId}/share	analyses	공유 중이 아니어도 204(명등)
F-ANALYSIS-010	공유된 분석 결과 조회	비회원 포함 누구나	공유 토큰	분석 결과(요약, 개인 식별 정보 제외)	공유 링크로 접근한 결과 화면	GET /api/public/analyses/shared/{shareToken}	analyses	유효하지 않거나 해제된 토큰이면 404


요구사항 ID	기능명	사용자	입력	출력	화면	API	관련 테이블 / AI 로직	예외 조건
F-CHAT-001	질문하기	회원	질문(2~1000자), 국가 코드, (선택) 세션 ID·비자 코드·분석 ID	답변, 답변 가능 여부, 출처 목록(제목/URL/기준일/점수)	AI 상담 화면	POST /api/chat	chat_sessions, chat_messages, chat_message_sources	근거 문서 유사도가 임계값(0.78) 미만이면 "근거 문서 없음"으로 답변 거부 — F-RAG-003
F-RAG-003	하이브리드 후보 검색	(시스템)	질문 임베딩, 국가 코드	dense(코사인)+keyword(전문검색) RRF 융합 후보 목록	- (내부 로직)	ai-server 내부	policy_chunks.embedding, policy_chunks.search_vector	질문이 코퍼스에 없는 개념이면 후보 유사도가 낮게 나옴
F-RAG-004	재랭킹	(시스템)	후보 청크 10개 + 질문	cross-encoder 점수로 재정렬된 상위 청크	- (내부 로직)	ai-server 내부(CPU, 필요 시 GPU API)	BAAI/bge-reranker-v2-m3	재랭커 API 실패 시 RRF 순위로 자동 폴백(요청은 실패하지 않음)
F-RAG-005	답변 생성	(시스템)	질문 + 임계값을 넘는 근거 청크	LLM 생성 답변(질문과 동일 언어)	- (내부 로직)	ai-server → vLLM(Qwen3-8B-AWQ)	-	LLM 서버 연결 실패 시 "일시적으로 연결할 수 없습니다" 응답, 답변 불가 처리
F-RAG-006	근거 없음 처리	(시스템)	임계값 이상 청크 0개	정중한 답변 거부 메시지, sources 빈 배열	AI 상담 화면("근거 문서 없음" 배지)	-	-	LLM 호출 자체를 하지 않음 ("don't guess" 원칙)
F-CHAT-002	상담 세션 상세 조회	회원(본인만)	세션 ID	세션 내 전체 대화(질문/답변/출처)	AI 상담 화면(히스토리에서 이어보기)	GET /api/chat/sessions/{sessionId}	chat_sessions, chat_messages	타인의 세션이면 403/404
F-CHAT-003	상담 세션 목록/검색	회원	(선택) 국가 코드, 키워드, 페이지	세션 요약 목록(제목, 국가, 생성/수정일)	AI 상담 화면(히스토리 패널)	GET /api/chat/sessions?countryCode=&keyword=&page=&size=	chat_sessions	조건에 맞는 세션 없으면 빈 목록

요구사항 ID	기능명	사용자	입력	출력	화면	API	관련 테이블	예외 조건
F-RESULT-001	분석 이력 목록	회원	페이지 번호	분석 이력(날짜, 대표 국가 ·점수 등)	내 결과 화면	GET /api/analyses? page=&size= (F- ANALYSIS-007과 동일 API)	analyses	비회원은 접근 시 로그인 화면으로 이동
F-RESULT-002	결과 상세 재조회	회원(본인만)	분석 ID	저장된 분석 결과 전체	내 결과 → 상세 화면	GET /api/analyses/{analysi sId} (F-ANALYSIS-006 과 동일 API)	analyses, analysis_cou ntry_results	타인의 결과 접근 시 403/404


요구사항 ID	기능명	사용자	입력	출력	화면	API	관련 테이블	예외 조건
F-PROFILE-001	내 계정 정보 조회	회원	-	사용자 ID, 이름, 이메일, 이메일 인증 여부	헤더/마이페이지	GET /api/users/me	users	-
F-PROFILE-002	인증 메일 재전송	회원(미인증)	-	204 No Content	상단 "이메일 인증이 완료 되지 않았습니다" 배너	POST /api/users/me/resent-verification	email_verification_tokens	이미 인증된 계정이면 처리 안 함
F-PROFILE-003	프로필 조회	회원	-	나이, 학력, 전공, 직업, 경력연수(저장된 경우)	분석 입력 화면(자동완성 용)	GET /api/users/me/profile	user_profiles	저장된 프로필 없으면 404
F-PROFILE-004	프로필 저장	회원	나이(1864), 학력, 전공, 직업, 경력연수(040)	저장된 프로필	분석 입력 화면	PUT /api/users/me/profile	user_profiles	값 범위를 벗어나면 400

화면 설계서

Living Abroad



화면 ID	화면명	위치	파일명
HOME-001	홈	/	HomeView.vue
AUTH-001	로그인	/auth?tab=login	AuthView.vue
AUTH-002	회원가입	/auth?tab=signup	AuthView.vue
ANA-001	AI 분석 1단계	/analysis/step-1	AnalysisStep1View.vue
ANA-002	AI 분석 2단계	/analysis/step-2	AnalysisStep2View.vue
ANA-003	AI 분석 로딩	/analysis/loading	AnalysisLoadingView.vue
RES-001	추천 결과	/results/{id}	AnalysisResultView.vue
CHAT-001	AI 상담	/chat	RiChatView.vue
MY-001	내 결과	/my-results	MyResultsView.vue



Description

Check Point

비로그인 사용자도 접근 가능한 공개 화면. CTA 클릭 시 로그인 여부에 따라 이동 경로가 분기됩니다.

- A1 "무료 AI 분석 시작하기" 클릭 → 로그인 시 /analysis/step-1, 비로그인 시 /auth?tab=login
- A2 "AI 상담 시작하기" 클릭 → /chat 이동 (비로그인 시 로그인 유도)
- A3 국가 카드 "분석하기" 클릭 → 해당 국가를 우선 선택한 채 분석 플로우 진입

A1로그인

A2회원가입

V1이메일 주소

you@example.com

V2비밀번호

비밀번호 찾기

.....

A3로그인

— 또는 —

G Continue with Google

Description

Check Point

JWT 기반 인증 — 로그인 성공 시
Access/Refresh 토큰 발급. Google 로그인
버튼은 Client ID 설정 시에만 노출됩니다.

A1 로그인 탭 클릭(현재 화면)

A2 회원가입 탭 클릭 → AUTH-002 회원가입(/auth?tab=signup)으로 전환

A3 "로그인" 버튼 클릭 → 인증 성공 시 /analysis/step-1 이동

V1 이메일 형식 검증(type=email), 미입력 시
제출 불가

V2 비밀번호 필수 입력

A1로그인

A2회원가입

V1이름

홍길동

V2이메일 주소

you@example.com

V3비밀번호

8자 이상 입력

V4비밀번호 확인

비밀번호 재입력

A3회원가입 완료

Description

Check Point

비밀번호와 비밀번호 확인이 다르면 서버 요청 없이 클라이언트 단에서 즉시 오류 메시지를 표시하고 제출을 막습니다.

- A1

로그인 탭 클릭 → AUTH-001 로그인 (/auth?tab=login)으로 전환
- A2

회원가입 탭 클릭(현재 화면)
- A3

"회원가입 완료" 클릭 → 계정 생성 성공 시 /analysis/step-1 이동
- V1

이름 필수 입력
- V2

이메일 형식 검증(type=email)
- V3

비밀번호 8자 이상
- V4

비밀번호 확인란과 일치 여부 검증(불일치 시 오류 표시)

① STEP 1 기본 자격 정보

② STEP 2

V1 나이 (만)

30

전공

예: 컴퓨터공학

총 관련 경력 연수

5 년

최종 학력

학력 선택 ▾

현재 직업

예: 소프트웨어 엔지니어

영어시험 종류

미응시 ▾

V2 영어 종합점수

시험 선택 시 필수

A1 다음 단계로 →

Description

Check Point

로그인 필요 화면. 실제 <form> + native validation 사용 — 유효하지 않으면 다음 단계로 진행할 수 없고 사유가 화면에 표시됩니다.

A1

"다음 단계로" 클릭 → 검증 통과 시 /analysis/step-2 이동, 실패 시 첫 번째 오류 필드의 사유를 하단에 표시하고 이동 차단

V1

나이 18~64, 학력/전공/직업/경력연수 (0~40) 필수

V2

영어시험 선택 시 영어 종합점수 필수 + 0 이상 숫자만 입력 가능

✓ STEP 1

— — —

② STEP 2 경력 및 선호 정보

V1 상세 경력기술서 (100~2000자)

주요 담당 업무, 프로젝트, 기술 스택을 작성해주세요...

V2 보유 자금 구간

구간 선택 ▾

가족 동반 여부

단독 이주

가족 동반

V3 관심 국가

CA 캐나다

AU 호주

GB 영국


상관없음

A1 ← 이전

A2 AI 분석 시작하기

Description
Check Point 1단계 입력값은 Pinia 스토어에 유지되어 "이전" 클릭 후 되돌아와도 그대로 보존됩니다.
A1 "← 이전" 클릭 → /analysis/step-1로 복귀(입력값 보존)
A2 "AI 분석 시작하기" 클릭 → 분석 요청 생성 후 /analysis/loading 이동
V1 상세 경력기술서 100~2000자 필수
V2 보유 자금 구간 필수 선택
V3 관심 국가 필수 선택(4지선다)

28



Description
Check Point 2.5초 간격으로 분석 상태를 폴링합니다. 상태가 COMPLETED가 되면 결과 화면으로 자동 이동하고, FAILED면 오류 메시지를 표시합니다.
A1 "분석 취소" 클릭 → 폴링 중단 후 /analysis/step-2로 복귀

AI 맞춤 이민 분석 결과

① 점수 안내

BEST MATCH

CA 캐나다

Express Entry

87

환경 82

유사도 91

AU 호주

Subclass 189

74

GB 영국

Skilled Worker

61

지표	캐나다	호주	영국
종합 적합도	87	74	61

준비 체크리스트

☐ 유효한 여권

☐ 공인 영어 성적표

A1 PDF 저장

A2 공유하기

A3 다시 분석

A4 AI에게 질문하기

Description

Check Point

본인 소유 분석 결과만 열람 가능 — 다른 사용자의 analysisId로 접근 시 403 처리됩니다.

A1

"PDF로 저장" 클릭 → 결과 리포트 PDF 다운로드

A2

"공유하기" 클릭 → 공유 링크 생성/토글

A3

"다시 분석하기" 클릭 → /analysis/step-1(수정 모드, 기존 입력값 자동 반영)

A4

"AI에게 결과 질문하기" 클릭 → /chat 이동(해당 국가 컨텍스트 유지)

A1CA 캐나다

A3 새 대화A4 히스토리

안녕하세요! 해외 이주 및 비자 관련하여 궁금한 점을 물어보세요.

A2#캐나다 Express Entry 기본 자격#캐나다 CRS 점수 산정 기준#캐나다 영어 점수 기준

캐나다 Express Entry 기본 자격이 어떻게 되나요?

CRS 점수, 학력, 경력, 언어 점수를 기준으로 자격을 산정합니다... IRCC 공식 문서

V1이주 계획에 대해 무엇이든 물어보세요...전송

Description
Check Point
RAG 기반 응답 — 근거 문서 유사도가 임계값 미만이면 "근거 문서 없음"으로 표시. 추천 태그는 이미 물어본 항목을 제외하고 다른 후보로 교체됩니다.
A1 국가 선택 변경 → 해당 국가 전용 추천 태그 3개로 갱신
A2 추천 태그 클릭 → 해당 질문 자동 전송 (물어본 태그는 다음 후보로 교체)
A3 "새 대화" 클릭 → 세션/태그 상태 초기화
A4 "히스토리" 클릭 → 과거 상담 세션 검색·조회
V1 질문 입력 2자 이상, 1000자 이하

안녕하세요, 진아님

🇰🇷

최근 분석일: 2026-07-28

A1

프로필 수정

최근 분석 이력

총 3건

분석일: 2026-07-28

CA 1위 추천: 캐나다 (CAN)

대표 비자: Express Entry

87점

종합 적합도

A2

다시 보기

Description

Check Point

분석 이력이 없으면 빈 상태 안내와 함께 첫 분석 시작 링크를 노출합니다.


A1

"프로필 수정" 클릭 → /analysis/step-1? mode=edit(이전 입력값 자동 채움)


A2

"다시 보기" 클릭 → /results/{id} 이동

[확대이미지 링크](#)



[확대이미지 링크](#)



테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
사용자 (users)	사용자 번호 (user_id)	BIGINT	N	사용자를 식별하는 고유 번호	PK, IDENTITY
	이메일 (email)	VARCHAR(255)	N	로그인 ID로 사용하는 사용자 이메일	UK
	비밀번호 해시 (password_hash)	VARCHAR(255)	N	암호화하여 저장한 비밀번호	
	사용자명 (user_name)	VARCHAR(50)	N	서비스에 표시되는 사용자 이름	
	계정 상태 (account_status)	VARCHAR(20)	N	계정의 활성·비활성·탈퇴 상태	ACTIVE / INACTIVE / WITHDRAWN
	생성 일시 (created_at)	TIMESTAMP	N	회원 계정 생성 일시	DEFAULT CURRENT_TIMESTAMP
	수정 일시 (updated_at)	TIMESTAMP	N	회원 정보 최종 수정 일시	DEFAULT CURRENT_TIMESTAMP

테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
사용자 프로필 (user_profiles)	프로필 번호 (profile_id)	BIGINT	N	사용자 프로필을 식별하는 고유 번호	PK, IDENTITY
	사용자 번호 (user_id)	BIGINT	N	프로필을 소유한 사용자 번호	FK → users.user_id, UK
	나이 (age)	SMALLINT	N	사용자의 만 나이	18~64
	최종 학력 (education_level)	VARCHAR(30)	N	사용자의 최종 학력	
	전공 (major)	VARCHAR(100)	Y	사용자의 전공명	
	현재 직업 (current_occupation)	VARCHAR(150)	N	현재 종사 중인 직업	
	경력 연수 (experience_years)	DECIMAL(4,1)	N	사용자의 총 경력 연수	DEFAULT 0
	언어 시험 종류 (language_test_type)	VARCHAR(30)	Y	IELTS 등 보유 언어 시험 종류	
	언어 점수 (language_score)	DECIMAL(6,2)	Y	사용자가 입력한 언어 시험 점수	
	보유 자금 (available_funds_krw)	BIGINT	N	원화 기준 사용 가능 보유 자금	DEFAULT 0
	가족 동반 여부 (family_accompanied)	BOOLEAN	N	해외 이주 시 가족 동반 여부	DEFAULT FALSE
	선호 국가 코드 (preferred_country_code)	VARCHAR(3)	Y	사용자가 선호하는 국가 코드	FK → countries.country_code
	경력 기술서 (career_description)	TEXT	Y	직무, 기술, 업무 경험을 작성한 경력 설명	
	생성 일시 (created_at)	TIMESTAMP	N	프로필 생성 일시	DEFAULT CURRENT_TIMESTAMP
	수정 일시 (updated_at)	TIMESTAMP	N	프로필 최종 수정 일시	DEFAULT CURRENT_TIMESTAMP

테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
분석 요청(analysis)	분석 번호 (analysis_id)	BIGINT	N	AI 분석 요청을 식별하는 고유 번호	PK, IDENTITY
	사용자 번호 (user_id)	BIGINT	N	분석을 요청한 사용자 번호	FK → users.user_id
	분석 상태 (analysis_status)	VARCHAR(20)	N	AI 분석 처리 상태	PENDING / PROCESSING / COMPLETED / FAILED
	입력 나이 (input_age)	SMALLINT	N	분석 요청 당시 사용자의 나이	
	입력 최종 학력 (input_education_level)	VARCHAR(30)	N	분석 요청 당시 최종 학력	
	입력 전공 (input_major)	VARCHAR(100)	Y	분석 요청 당시 전공	
	입력 현재 직업 (input_current_occupation)	VARCHAR(150)	N	분석 요청 당시 현재 직업	
	입력 경력 연수 (input_experience_years)	DECIMAL(4,1)	N	분석 요청 당시 경력 연수	DEFAULT 0
	입력 언어 시험 종류 (input_language_test_type)	VARCHAR(30)	Y	분석 요청 당시 언어 시험 종류	
	입력 언어 점수 (input_language_score)	DECIMAL(6,2)	Y	분석 요청 당시 언어 점수	
	입력 보유 자금 (input_available_funds_krw)	BIGINT	N	분석 요청 당시 원화 기준 보유 자금	DEFAULT 0
	입력 가족 동반 여부 (input_family_accompanied)	BOOLEAN	N	분석 요청 당시 가족 동반 여부	DEFAULT FALSE
	입력 선호 국가 코드 (input_preferred_country_code)	VARCHAR(3)	Y	분석 요청 당시 선호 국가 코드	FK → countries.country_code
	입력 경력 기술서 (input_career_description)	TEXT	N	분석 요청 당시 입력한 경력 설명	
	모델 버전 (model_version)	VARCHAR(50)	Y	분석에 사용한 AI 모델 버전	
	데이터 버전 (data_version)	VARCHAR(50)	Y	분석에 사용한 학습·기준 데이터 버전	
	요청 일시 (requested_at)	TIMESTAMP	N	AI 분석 요청 일시	DEFAULT CURRENT_TIMESTAMP
	완료 일시 (completed_at)	TIMESTAMP	Y	AI 분석 처리 완료 일시	
	오류 메시지 (error_message)	TEXT	Y	분석 실패 시 발생한 오류 내용	

테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
국가별 분석 결과 (analysis_country_results)	결과 번호 (result_id)	BIGINT	N	국가별 분석 결과를 식별하는 고유 번호	PK, IDENTITY
	분석 번호 (analysis_id)	BIGINT	N	결과가 생성된 원본 분석 요청 번호	FK → analyses.analysis_id
	비자 프로그램 번호 (visa_program_id)	BIGINT	N	평가 대상 비자 프로그램 번호	FK → visa_programs.visa_program_id
	추천 순위 (rank_position)	SMALLINT	N	분석 결과의 국가·비자 추천 순위	1~3
	종합 점수 (total_score)	DECIMAL(5,2)	N	규칙·환경·경력·선호도를 합산한 종합 적합도	0~100
	규칙 점수 (rule_score)	DECIMAL(5,2)	N	비자 자격 규칙 기반 평가 점수	0~100
	환경 점수 (environment_score)	DECIMAL(5,2)	N	국가 환경 데이터 기반 평가 점수	0~100
	경력 유사도 점수 (career_similarity_score)	DECIMAL(5,2)	N	사용자 경력과 국가별 직업의 유사도 점수	0~100
	선호도 점수 (preference_score)	DECIMAL(5,2)	N	사용자의 국가 선호도를 반영한 점수	0~100
	자격 판정 상태 (eligibility_status)	VARCHAR(20)	N	비자 기본 조건 충족 여부에 대한 판정 상태	ELIGIBLE / CONDITIONAL / NOT_ELIGIBLE / UNKNOWN
	결과 요약 (result_summary)	TEXT	Y	국가별 추천 결과 요약 설명	
	생성 일시 (created_at)	TIMESTAMP	N	분석 결과 생성 일시	DEFAULT CURRENT_TIMESTAMP


테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
국가별 직업 (occupations)	직업 번호 (occupation_id)	BIGINT	N	국가별 직업을 식별하는 고유 번호	PK, IDENTITY
	국가 코드 (country_code)	VARCHAR(3)	N	직업 분류가 속한 국가 코드	FK → countries.country_code
	직업 분류 체계 (classification_system)	VARCHAR(20)	N	국가별 공식 직업 분류 체계	NOC / ANZSCO / SOC
	직업 코드 (occupation_code)	VARCHAR(30)	N	국가 기관에서 부여한 공식 직업 코드	복합 UK
	직업명 (occupation_title)	VARCHAR(200)	N	공식 직업명	
	직업 설명 (occupation_description)	TEXT	Y	주요 업무와 직업 상세 설명	
	기술 수준 (skill_level)	VARCHAR(50)	Y	공식 직업 분류상 기술 수준	
	공식 URL (official_url)	TEXT	Y	공식 직업 정보 페이지 주소	
	사용 여부 (is_active)	BOOLEAN	N	현재 추천 분석에 사용할 직업인지 표시	DEFAULT TRUE
	생성 일시 (created_at)	TIMESTAMP	N	직업 데이터 생성 일시	DEFAULT CURRENT_TIMESTAMP

테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
직업 매칭 결과 (analysis_occupation_matches)	매칭 번호 (match_id)	BIGINT	N	직업 매칭 결과를 식별하는 고유 번호	PK, IDENTITY
	결과 번호 (result_id)	BIGINT	N	직업 매칭이 속한 국가별 분석 결과 번호	FK → analysis_country_results.result_id
	직업 번호 (occupation_id)	BIGINT	N	사용자 경력과 매칭된 국가별 직업 번호	FK → occupations.occupation_id
	유사도 점수 (similarity_score)	DECIMAL(5,2)	N	사용자 경력과 직업 설명 간 유사도 점수	0~100
	매칭 순위 (match_rank)	SMALLINT	N	국가별 추천 직업 순위	
	매칭 이유 (match_reason)	TEXT	Y	해당 직업을 추천한 근거 설명	
	생성 일시 (created_at)	TIMESTAMP	N	직업 매칭 결과 생성 일시	DEFAULT CURRENT_TIMESTAMP

테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
상담 세션 (chat_sessions)	세션 번호 (session_id)	BIGINT	N	AI 상담 세션을 식별하는 고유 번호	PK, IDENTITY
	사용자 번호 (user_id)	BIGINT	N	상담 세션을 소유한 사용자 번호	FK → users.user_id
	분석 번호 (analysis_id)	BIGINT	Y	상담과 연결된 분석 요청 번호	FK → analyses.analysis_id
	비자 프로그램 번호 (visa_program_id)	BIGINT	Y	상담 대상 비자 프로그램 번호	FK → visa_programs.visa_program_id
	세션 제목 (session_title)	VARCHAR(200)	Y	상담 대화방의 제목	
	생성 일시 (created_at)	TIMESTAMP	N	상담 세션 생성 일시	DEFAULT CURRENT_TIMESTAMP
	수정 일시 (updated_at)	TIMESTAMP	N	상담 세션 최종 수정 일시	DEFAULT CURRENT_TIMESTAMP


테이블 명	컬럼 명	데이터 타입	NULL 허용	설명	비고
상담 메시지 (chat_messages)	메시지 번호 (message_id)	BIGINT	N	상담 메시지를 식별하는 고유 번호	PK, IDENTITY
	세션 번호 (session_id)	BIGINT	N	메시지가 속한 상담 세션 번호	FK → chat_sessions.session_id
	메시지 역할 (message_role)	VARCHAR(20)	N	메시지 작성 주체	USER / ASSISTANT
	메시지 내용 (message_content)	TEXT	N	사용자 질문 또는 AI 답변 내용	
	답변 가능 여부 (answerable)	BOOLEAN	Y	공식 정책 근거로 답변 가능한 질문인지 표시	
	생성 일시 (created_at)	TIMESTAMP	N	메시지 생성 일시	DEFAULT CURRENT_TIMESTAMP

RAG 기반 LLM 답변 생성 구조





환각(hallucination) 방지 — 이중 게이트



한계 — 정량 검증 결과 (임계값 0.78)

재현율

64%

오탐율

12.5%


단일 임계값만으로는 재현율·오탐율을 동시에 만족시키지 못함을 확인 — 근본 원인은 임계값이 아니라 같은 국가 내 주제가 겹치는 문서 간 검색 정확도 한계(top-1 76%)로 분석됨.

후속 개선 — Cross-Encoder 재랭킹

BAAI/bge-reranker-v2-m3로 top-1 검색 정확도를 76% → 80%로 개선(실측 확인). 다만 게이트는 여전히 원본 코사인 유사도를 기준으로 하므로, 채택 임계값(0.78)에서의 재현율·오탐율 자체는 그대로 — 개선 효과를 온전히 체감하려면 게이트 기준 자체를 재랭킹 점수로 바꾸는 후속 작업이 필요함.

※ 이 페이지는 최초 dense-only 검색 기준 분석입니다. 이후 하이브리드(dense+keyword) 검색은 언어 불일치로 효과 없음을 확인했고, cross-encoder 재랭킹만 유의미한 개선을 보였습니다 — 두 실험 모두 정량 검증을 거쳐 채택/보류를 결정했습니다.


LLM으로 Qwen 을 선택한 이유



비교 기준	Qwen3-8B-AWQ (채택)	GPT-4o-mini · Claude Haiku (외부 API)	Llama 3.1 8B	Gemma 2 9B
한국어·영어 동시 처리	✓ 적합 사용자는 한국어로 질문하지만 근거 문서(RAG 코퍼스)는 canada.ca/gov.uk 등 영어 원문 — 두 언어를 함께 다루는 다국어 RAG 상담에 적합	다국어 성능 우수하지만 질의응답 내용이 외부 서버로 전송됨	다국어 성능 보통	다국어 성능 보통
라이선스 · 배포 편의성	✓ Apache 2.0 공식 AWQ(양자화) 체크포인트 제공 — 자체 GPU 서버에 직접 호스팅한다는 프로젝트 요구사항에 맞춰 구성이 단순함	해당 없음 — 자체 호스팅 불가(관리형 API 전용)	Llama 3 Community License — 상업적 사용 제약 조항	Gemma 라이선스 — 사용 제약 조항
모델 크기 · 비용	✓ 8B MVP 우선순위에 맞춤 — 14B 이상 대비 GPU 비용·응답 지연 낮음. AWQ 양자화로 16~24GB급 GPU 1장으로 운용 가능	토큰당 종량제 — 트래픽에 따라 비용 예측이 어려움	유사 크기지만 라이선스 제약으로 후순위	유사 크기지만 라이선스 제약으로 후순위
vLLM과의 궁합	✓ 최적화 continuous batching + OpenAI 호환 API 지원으로 FastAPI 연동 코드가 단순해짐	해당 없음 — 이미 API 형태로만 제공	vLLM 지원되나 라이선스 제약은 그대로 남음	vLLM 지원되나 라이선스 제약은 그대로 남음

pgvector 선택 이유

Living Abroad




전용 벡터 DB(Pinecone·Weaviate·Milvus) 대신 pgvector를 채택한 이유 — 4가지 기준 비교

비교 기준	pgvector (채택)	Pinecone	Weaviate	Milvus
DB 구조 통합	✓ 단일 DB 기존 PostgreSQL에 확장 설치만으로 벡터 검색 추가, 단일 VM 배포 구조에 적합	별도 관리형 벡터 전용 DB — 시스템이 하나 더 늘어남	별도 벡터 전용 DB — 자체 호스팅 시 서버 추가 필요	별도 벡터 전용 DB — 다중 컴포넌트로 구성
필터링 + 검색	✓ SQL 한 번 policy_chunks·policy_documents JOIN으로 국가 필터링 + 코사인 정렬을 한 쿼리로 처리	관계형 필터와 벡터 검색을 애플리케이션 레벨에서 별도로 병합해야 함	애플리케이션 레벨에서 별도 병합 필요	애플리케이션 레벨에서 별도 병합 필요
현재 데이터 규모 적합성	✓ 충분 정책 청크 82건, 직업 임베딩 약 2천 건 — HNSW 인덱스만으로 충분	수백만~수억 건 규모에 특화 — 현재 규모엔 과함	대규모 특화 — 현재 규모엔 과함	대규모 특화 — 현재 규모엔 과함
비용 · 인프라	✓ 무료 오픈소스, 공식 pgvector/pgvector Docker 이미지로 추가 배포 인프라 없이 사용	관리형 SaaS — 별도 과금 발생	자체 호스팅 시 별도 서버 비용	자체 호스팅 시 다중 컴포넌트로 운영 부담 큼

AI/ML/DL 전처리 방법

Living Abroad



공통 원칙: 세 서브시스템 모두 지도학습 라벨(정답 데이터)이 없어 전통적인 train/test 검증이 불가능함 — 각 파이프라인에 맞는 방식으로 사후 검증을 대체함.

1. ML (K-Means, 국가 환경 점수)

입력

36개국 × 원시 피쳐 9개(이민자 stock 규모, stock 증가율, 여성 비율, 유입 증가율, 외국인 비율, 외국 출생 비율, 국적 취득률, 외국 출생 고용률, 외국 출생 고학력 비율)

결측치 처리

컬럼별 1~10개국 결측 → 중앙값 대체(median imputation)

스케일링


Min-Max Scaling (0~1)

검증

원본 제공된 *_scaled 컬럼과 자체 재현 스케일링 결과를 대조해 로직 일치 확인(비결측 값 완전 일치) — 실제 모델링은 원본 *_scaled 컬럼 사용

제외 컬럼

국가 식별자(iso3, country_name), 정답 라벨 사용 금지 컬럼 (environment_score_rule_based, 참고 비교용)



2. DL (Sentence Transformer, 경력·직업 매칭)

국가별로 형식이 다른 직업분류 데이터를 하나의 공통 스키마로 통합하는 것이 핵심.

국가	분류체계	전처리
캐나다	NOC 2021	최하위 계층(Unit Group)만 필터링, 코드 5자리 정규화, 제목+정의문 사용
호주	ANZSCO	6자리 세부 코드만 필터링, 상위 집계 코드(nfd) 제외, 설명문 부재로 제목을 설명으로 대체 사용
영국	SOC 2020	기존 데이터(대분류만)가 직업 단위 매칭에 부적합해 ONS 공식 원본으로 재확보, 4자리 Unit Group 필터링, 설명·직무·관련직업명 포함


- 통합: 3개국 데이터를 "제목. 설명" 형태의 임베딩 입력 텍스트로 통일, 모델 최대 시퀀스 길이(512 토큰)에 맞춰 2000자로 절단
- 임베딩: 사전학습 intfloat/multilingual-e5-base 재사용(모델 재학습 없음), 비대칭 검색 방식(passage:/query: 접두어) 적용
- 검증: 실제 경력기술서 예시(개발자·간호사·교사)로 상위 매칭의 타당성 확인, 접두어 유무 비교


문서 수집 — 정부 공식 사이트의 봇 차단으로 브라우저 직접 접속 방식 채택, 원문을 영어로 요약·재구성해 저장(메타데이터 헤더 포함)

청킹 알고리즘 (목표 500~800자)



K-Means







k	2	3	4	5	6	7	8
Silhouette	0.170	0.183	0.193	0.203	0.207 ✓ 채택	0.168 (급락)	0.213 (argmax, 불안정)

채택 근거 — 단순 argmax는 k=8(0.213)을 고르지만, k=7에서 급락(0.168)했다가 k=8에서 다시 튀는 불안정한 패턴이다. 국가 수가 36개뿐인 소규모 데이터셋에서 k=8은 군집당 평균 4.5개국으로 과적합·해석 불가능한 군집 위험이 크다고 판단해, **k=2~6의** 완만하고 안정적인 상승 구간의 마지막 지점인 **k=6**을 최종 선택했다(실루엣 손실은 argmax 대비 0.006에 불과).

전체 36개국으로 학습(k=6), 결과에서 MVP 3개국(CAN·AUS·GBR)만 조회



PCA 2D 투영 — 국가 환경 군집 분포




MVP 3개국 environment_score (0~100)

국가	군집 유형	environment_score
캐나다 (CAN)	안정형	53.59
호주 (AUS)	성장형	49.42
영국 (GBR)	성장형	42.63

시스템 마무리

Living Abroad



구분	문제 상황	원인	해결
백엔드 연동	Spring→FastAPI 요청 시 body가 null로 도착 (422)	JDK HttpClient의 기본 HTTP/2 업그레이드를 uvicorn(HTTP/1.1 전용)이 거부	HttpClient.Version.HTTP_1_1 명시적 지정
백엔드 연동	Refresh 토큰 재발급 요청이 401로 거부	만료된 Bearer 토큰이 헤더에 있으면 permitAll()이어도 Security 필터가 선(先)거부	/api/auth/** 요청에 Authorization 헤더 미첨부 처리
배포 (GCP)	이미지 빌드 중 no space left on device	부팅 디스크 10GB로 시작 (PyTorch 이미지만 ~2GB)	30GB로 증설
배포 (RunPod)	vLLM 컨테이너가 unrecognized arguments로 크래시	이미지 ENTRYPOINT가 이미 vllm serve인데 명령어 중복/\${VAR} 문법 사용	Start Command에 모델명+플래그만 입력
배포 (RunPod)	답변에 <think>...</think> 태그 노출	enable_thinking은 서버 플래그가 아니라 요청별 파라미터	매 요청 extra_body로 false 전달 + 방어적 정규식 제거
배포 (GCP)	nginx 설정 변경이 재배포해도 반영 안 됨	Compose가 바인드마운트 파일 내용 변경을 감지 못해 컨테이너 미재생성	배포 절차에 docker compose restart nginx 추가
인증	Google 로그인이 400 origin_mismatch로 실패	Google Cloud Console에 배포 도메인이 승인된 원본으로 미등록	OAuth 클라이언트에 로컬/배포 도메인 등록
데이터 수집	정책 문서 자동 수집이 403/타임아웃으로 반복 실패	canada.ca·gov.uk의 봇 탐지 차단	실제 브라우저로 직접 접속해 25건 수집
데이터 수집	RAG 문서 재적재 시 FK 위반으로 삭제 실패	chat_message_sources가 policy_chunks를 참조(ON DELETE RESTRICT)	재적재 전 chat_message_sources 선(先) 삭제

이번 프로젝트에서 가장 크게 배운 건 "정답 라벨이 없을 때 무엇을 하지 않을지 아는 것"도 설계 능력이라는 점이었습니다. 비자 승인 여부를 예측하는 모델은 애초에 만들 수 없었기에, 규칙 엔진·K-Means·사전학습 임베딩·RAG로 각자 풀 수 있는 만큼만 풀도록 역할을 나눴습니다. RAG 임계값을 튜닝할 때도 "오답을 줄이는 것"과 "정답을 놓치지 않는 것" 사이에서 어느 실패가 더 안전한지 고민했고, 결국 "모른다고 말하는 게 틀리게 아는 척하는 것보다 낫다"는 원칙을 코드 레벨로 강제했습니다.

배포 과정에서도 Docker Desktop이 원인불명으로 영구히 망가져 네이티브 PostgreSQL과 pgvector를 직접 빌드해야 했고, GCP·RunPod을 오가며 사소하지만 답을 찾기 어려운 문제들을 하나씩 좁혀나갔습니다.

3주 안에 혼자 기획부터 배포까지 끝냈다는 것보다, 매 순간 "이 점수가 실제로 뭘 의미하는지" 스스로 검증하며 만들었다는 점이 가장 기억에 남습니다.

